

BLM0463-Veri Madenciliđi Proje Ödevi Raporu

Öğrenci Bilgileri:

İsim-Soyisim: Yusuf Çil

Numara: 22360859012

Rapor İçeriđi

1.Verit Setinin Tanıtımı

2.Preprocessing İşlemlerinin Açıklanması

3.Kullanılan Modelin ve Yöntemlerin Açıklanması

4.Grafik Yorumlamalarının Yapılması

5.Akademik Bir Çalışma ile Sonuçların Kıyaslanması

6.Bağlantılar

7.Kaynakça

1.Verit Setinin Tanıtımı:

BLM0463-Veri Madenciliđi dersi kapsamında verilen proje ödevinde UCI Machine Learning Repository sitesinden Adult veri seti seçilmiştir. Adult veri seti, 1994 yılında Amerika Birleşik Devletleri Nüfus Sayım Bürosu (U.S. Census Bureau) tarafından toplanan gerçek ham nüfus verilerinden üretilmiştir. Makine öğrenmesi dünyasına

kazandıran kişi ise Ron Kohavi'dir. Adult veri seti, bir bireyin sosyo-ekonomik ve demografik özelliklerine bakarak, o kişinin yıllık gelirinin 50.000 doları aşp aşmadığını tahmin etmeyi sağlamaktadır. 1994 yılı şartlarında yıllık 50.000 dolarlık gelir, ABD standartlarında orta sınıf ile üst-orta sınıf (refah düzeyi yüksek) arasındaki sınır çizgisi olarak kabul ediliyordu. Dolayısıyla modelin aslında bir kişinin "zengin veya yüksek refah seviyesine sahip" olup olmadığını tahmin edilmeye çalışılmaktadır. Tüm bu bilgilere ek olarak Adult veri seti preprocessing işlemleri ile temizlenmeden önce toplamda 32561 adet satır bulunmaktadır. Preprocessing işlemleri ile bu sayı 30162'ye kadar düşmektedir. Projede kullanılan yapay zeka algoritması da 30162 tane olan preprocessing yapılmış ve temizlenmiş veri setini kullanır. Adult veri setinde sütunların temsil ettikleri ise sırasıyla şöyledir:

Demografik Özellikler:

- age (yaş)
- sex (cinsiyet)
- race (ırk)

Eğitim Seviyesi:

- education (en son mezun olunan okul)
- education-num (toplam eğitim alınan yıl süresi)

Medeni Durum ve Aile Yapısı:

- marital-status (medeni hal)
- relationship (aile içerisindeki rol->eş, çocuk, yalnız vb.)

İş Çalışma Hayatı:

- workclass (çalışma sektörü: özel sektör, devlet memuru, serbest meslek vb.)

Finansal Göstergeler:

- capital-gain (sermaye kazancı-hisse senedi, mülk satışı vb. gelirler)
- capital-loss (sermaye kaybı)

Ağırlık Faktörü:

- fnlwgt (Bu değer, o satırdaki kişinin gerçek nüfusta kaç kişiyi temsil ettiğini gösteren istatistiksel bir ağırlıktır)


2.Preprocessing İşlemlerinin Açıklanması:

Adult veri seti, başlangıçta içerisinde bilinmeyen veya eksik değerler (?) içeren bir veri setidir. Daha sonrasında bir makine öğrenmesi algoritması ile verilerin işlenebilmesi için eksik veya bilinmeyen değerleri içeren satırların veri

setinden atılması gerekmektedir. Preprocessing işlemi, main.py dosyası içerisinde 32561 satır içerisinde yer alan ve değeri “?” olan değerleri NaN (boş eleman) olarak değiştirilir ve daha sonra silinir. Daha sonra one-hot encoding ile veriler makine öğrenmesi algoritmasının anlayabileceği formata çevrilir ve adult_preprocessed.csv dosyası olarak kaydedilir.



3.Kullanılan Modelin ve Yöntemlerin Açıklanması:

Projede kullanılan makine öğrenmesi Random Forest Algoritmasıdır. Bu algoritmanın temel özelliği karar ağacı yapısının kullanılıyor olmasıdır. Bu yöntemle alt ağaçlar kullanılarak hem regresyon hem de sınıflandırma yapılır ve en sonunda karar verilmiş olur.



4.Grafik Yorumlamalarının Yapılması:

Adult veri setinin Random Forest Algoritması ile işlenmesi sonucu ortaya çıkan Confusion Matrix ve Feature Importance grafikleri aşağıda verilmiştir.



Bu grafiklere göre yapılacak yorumlar ise şöyledir:

Feature Importance grafiği, Random Forest modelinin bir bireyin yüksek gelirli olup olmadığına karar verirken en çok hangi sosyo-ekonomik ve demografik özelliklere dikkat

ettiğini (ağırlık verdiğini) göstermektedir. Grafiğe göre geliri en çok etkileyen kritik faktörler şu şekildedir:

- 1. Evlilik ve Aile Durumu (marital-status_Married-civ-spouse / relationship_Husband):** Grafikte en üst sıralarda yer alan evlilik durumu, modelin karar mekanizmasında çok büyük bir paya sahiptir. Literatür incelendiğinde, 1994 yılı sosyo-ekonomik yapısında evli bireylerin ve aile reislerinin finansal istikrarlarının ve birleşik hane gelirlerinin daha yüksek olma eğiliminde olduğu görülmektedir. Modelimiz bu toplumsal örüntüyü başarıyla yakalamıştır.
- 2. Eğitim Süresi (education-num):** Bireyin toplam eğitim aldığı yıl süresi, geliri doğrudan etkileyen ikinci en büyük faktördür. Eğitim seviyesi arttıkça (Lisans, Yüksek Lisans, Doktora vb.) yüksek gelir grubuna dahil olma ihtimalinin matematiksel olarak arttığı model tarafından doğrulanmıştır.
- 3. Yaş (age):** Yaş faktörünün üst sıralarda yer alması, iş hayatındaki kıdem, tecrübe ve kariyer basamakları ile paralellik göstermektedir. Genç yaştaki bireylerin giriş seviyesi maaşlar alması, yaşlandıkça ve tecrübe kazandıkça gelirin artması durumunu model kararlarına yansıtmıştır.
- 4. Finansal Göstergeler (capital-gain / capital-loss):** Sermaye kazancı ve kayıpları, doğrudan bireyin ekstra

yatırım gücünü (hisse senedi, mülk vb.) gösterdiği için modelin kestiriminde doğrudan bir çarpan rolü oynamaktadır.

Yapılan bu analiz, kurulan Random Forest Algoritmasının sadece kuru sayılardan ibaret bir tahmin yapmadığını; eğitim, yaş ve aile yapısı gibi sosyolojik ve ekonomik gerçekliklerle tamamen örtüşen mantıklı ve tutarlı bir karar ağacı ormanı inşa ettiğini kanıtlamaktadır.

Bir diğer grafiğe göre ise:

Karışıklık Matrisi (Confusion Matrix), eğittiğimiz Random Forest modelinin test setindeki tahmin performansını sınıflar bazında detaylı olarak göstermektedir. Matris incelendiğinde şu sonuçlar elde edilmiştir:

- **Doğru Negatifler (True Negatives – Grafikte Sol Üst Kare):** Modelimiz, yıllık geliri 50K dolardan düşük olan ($\leq 50K$) 4503 kişiden **4298 adedini** doğru tahmin etmiştir. Bu sınıftaki yakalama oranı (**Specificity**) **%95** gibi oldukça yüksek bir seviyededir.
- **Doğru Pozitifler (True Positives – Grafikte Sağ Alt Kare):** Yıllık geliri 50K dolardan yüksek olan ($> 50K$) 1530 kişiden **880 adedini** doğru tahmin edebilmiştir. Bu sınıftaki yakalama oranı (**Sensitivity / Recall**) ise **%58** seviyesindedir.

Analiz: Modelin düşük gelirli sınıfı (0) tahmin etmede, yüksek gelirli sınıfına (1) kıyasla çok daha başarılı olduğu açıkça görülmektedir. Bu durumun temel sebebi, veri

setindeki sınıf dengesizliđidir (Class Imbalance). Orijinal veride düşük gelirli bireylerin sayısı yüksek gelirlilere kıyasla yaklaşık 3 kat daha fazladır. Algoritma, elinde daha fazla veri olan çoğunluk sınıfının örüntülerini daha iyi öğrenmiş ve 'garantici' bir eğilim göstererek bu sınıfta daha yüksek başarı yakalamıştır. Bu durum, veri madenciliđi projelerinde sıkça karşılaşılan ve kabul edilebilir bir doğal sonuçtur."

5.Akademik Bir Çalışma ile Sonuçların Kıyaslanması:

"Veri setini literatüre kazandıran Ron Kohavi'nin 1996 yılındaki çalışmasında, o dönemin popüler algoritmaları (C4.5 Karar Ağacı, Naive Bayes vb.) kullanılmış ve elde edilen en yüksek doğruluk oranları (Accuracy) %84.05 ile %84.46 civarında kalmıştır. Bu projede uyguladığımız modern bir topluluk (ensemble) öğrenme algoritması olan Random Forest, hiperparametre optimizasyonu (max_depth=12, min_samples_split=5) ile eğitildiğinde test setinde %85.83 doğruluk oranına ulaşmıştır. Bu sonuç, projede elde edilen modelin literatürdeki temel çalışmalardan yaklaşık %1.4 daha yüksek bir başarı gösterdiğini ve verinin ezberlenmeden (overfitting yaşama riski olmadan çünkü Train: %86.73 - Test: %85.83) başarıyla genellendiğini kanıtlamaktadır."

6.Bağlantılar:

Projenin GitHub Linki:

https://github.com/ysfcl/BLM0463-Data_Mining_Projesi

Projenin Youtube Linki:

<https://youtu.be/epQA5NumRt0>

7.Kaynakça:

-UCI Machine Learning Repository:

<https://archive.ics.uci.edu/>

- Kohavi, R. (1996). "Scaling Up the Accuracy of Naive-Bayes Classifiers: a Decision-Tree Hybrid." Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD), s. 202-207.

-UCI Adult Veri Seti

<https://archive.ics.uci.edu/dataset/2/adult>

-Visual Studio Code IDE

-GitHub